

Programowanie komunikacji człowiek-komputer

dr inż. Joanna Ochelska-Mierzejewska

DTD

Definicja typu dokumentu (ang. Document Type Definition)

3

Po co nam formalizacja struktury?

- Dostępność logicznej struktury treści pomaga lepiej przetwarzać dokumenty
- Zamiast pilnować poprawności danych „samemu” (w naszej aplikacji) możemy zlecić sprawdzanie poprawności automatu, który wymusi poprawność budowy dokumentu
- Przeniesienie zadania sprawdzania poprawności na parser daje spore oszczędności (ponoć aż 60% kodu programów dotyczy weryfikacji poprawności danych)

4

Struktura dokumentu – idea

- Mamy stworzyć dokument opisujący osobę, który ma posiadać element główny <osoba>, w którym znajdują się elementy <imie>, <nazwisko> i <adres> w tej właśnie kolejności. Z tym że dana osoba może mieć więcej niż jedno imię, natomiast nie musi mieć zdefiniowanego adresu

```
<osoba>
  <imie> Jan </imie>
  <nazwisko> Kowalski </nazwisko>
  <adres> Młoczańska 215 </adres>
</osoba>
```

```
<osoba>
  <imie> Jan </imie>
  <nazwisko> Kowalski </nazwisko>
</osoba>
```

```
<osoba>
  <imie> Jan </imie>
  <imie> Adam </imie>
  <nazwisko> Kowalski </nazwisko>
  <adres> Młoczańska 215 </adres>
</osoba>
```


5

Modelowanie struktury logicznej

- Modelowanie struktury dokumentów to
 - Określenie zestawu dopuszczalnych elementów i atrybutów
 - Przypisanie atrybutów do elementów
 - Definiowanie dopuszczalnej zawartości elementów (tekst, inne elementy)

6

Projektowanie struktury abstrakcyjnej




7

Formalizmy opisu struktury

- Metody opisu struktury
 - Brak struktury
 - DTD – Definicja Typu Dokumentu (ang. Document Type Definition)
 - XML Schema (wiele możliwości)
 - Inne (Relax NG, Schematron, ...)

8

Poprawność dokumentu a DTD



9

Poprawność dokumentu

- Dokument XML-owy jest
 - Poprawny składniowo (ang. well-formed), gdy
 - Ma tylko jeden element główny
 - Znaki początkowe i końcowe „pasują do siebie” (każdy element zamknięty, znaki nie nakładają się na siebie)
 - Wartości atrybutów są ujęte w cudzysłowy lub apostrofy
 - ... inne wymagania ujęte w specyfikacji
 - Poprawny strukturalnie (ang. valid), gdy
 - Jest poprawny składniowo
 - Jest zgodny z ustaloną wcześniej strukturą logiczną
 - Zostały określone wszystkie wymagane atrybuty
 - ... inne wymagania

10

Definicja elementu

<!ELEMENT nazwaElementu typElementu>

- Definicja składa się z trzech części
 - Słowa kluczowego **ELEMENT**
 - Nazwy danego elementu, czyli nazwy znacznika
 - Słowa lub grupy słów definiujących jego zawartość (**typElementu**)
- Element może
 - Być pusty
 - Zawierać tekst (treść)
 - Zawierać nieokreśloną postać (niezakończony w finalnej postaci DTD, pomocniczy przy wyrażaniu definicji elementów)
 - Zawierać jeden lub więcej elementów-dzieci (podelementy)
 - Zawierać tekst i podelementy (mieszany)
- Każdy element musi być zadeklarowany

11

Definicja elementu pustego

<!ELEMENT nazwaElementu typElementu>

- typElementu = EMPTY** deklaruje elementy puste
- Nie używa się nawiasów, ani innych deklaracji elementów
- Element pusty może posiadać atrybuty

DTD: **<!ELEMENT sesja EMPTY>**

XML: **<sesja />**

12

Definicja elementu tekstowego (dowolny)

<!ELEMENT nazwaElementu typElementu>

- typElementu = (#PCDATA)** opisuje podstawowe elementy, które zawierają analizowane dane znakowe
- Dane te są wierszem tekstu i mogą zawierać odniesienia jednostek, takich jak `>` lub `<`
- Nie mogą zawierać innych znaczników lub elementów potomnych

DTD: **<!ELEMENT klient (#PCDATA)>**

XML: **<klient>Jan Kowalski</klient>**

13

Definicja elementu nieokreślonego

<!ELEMENT nazwaElementu typElementu>

- typElementu = ANY deklaruje element, który może posiadać dowolny typ zawartości
- Nie używa się nawiasów, ani innych deklaracji elementów

DTD: **<!ELEMENT mój ANY>**

XML: **<mój/>**

XML: **<mój>Jan Kowalski</mój>**

XML: **<mój>Jan Kowalski<twój>Jan Nowak</twój></mój>**

14

Definicja elementu z podelementami

<!ELEMENT nazwaElementu typElementu>

- typElementu = (grupaElementów)
- grupaElementów zawiera przynajmniej jeden symbol (token) opisujący podelement danego elementu
- W przypadku, gdy model zawiera więcej niż jeden symbol, elementy dzieci mogą być organizowane na dwa sposoby: sekwencyjny i wyburu

DTD:

<!ELEMENT zamówienie (klient)>

<!ELEMENT klient (#PCDATA)>

XML:

<zamówienie><klient>Jan Kowalski</klient></zamówienie>

15

Definicja elementu z podelementami

DTD:

<!ELEMENT zamówienie (nrZamówienia, klient)>

<!ELEMENT nrZamówienia (#PCDATA)>

<!ELEMENT klient (#PCDATA)>

XML:

<zamówienie><nrZamówienia>123</nrZamówienia>

<klient> Jan Kowalski </klient>

</zamówienie>

DTD:

<!ELEMENT zamówienie (nrZam | nrKlient | NIP)>

<!ELEMENT nrZam (#PCDATA)>

<!ELEMENT nrKlient (#PCDATA)>

<!ELEMENT NIP (#PCDATA)>

XML:

<zamówienie>

<nrZam> 123 </nrZam>

</zamówienie>

XML:

<zamówienie>

<nrKlient> 456 </nrKlient>

</zamówienie>

XML:

<zamówienie>

<NIP> 123-234-45-56 </NIP>

</zamówienie>

16

Definicja elementu mieszanego

<!ELEMENT nazwaElementu typElementu>

- Składa się z treści tekstowej przeplatanej podelementami
- typElementu = (#PCDATA | element | element2)*

DTD:

<!ELEMENT produkt (#PCDATA | pozycja)*>

<!ELEMENT pozycja (#PCDATA)>

XML: **<produkt>bułki</produkt>**

XML: **<produkt><pozycja>12</pozycja></produkt>**

XML: **<produkt><pozycja>12</pozycja>bułki</produkt>**

XML: **<produkt>bułki<pozycja>12</pozycja>**

masło</produkt>

17

Określenie liczby wystąpień elementów

		Element występuje dokładnie raz
?	Opcjonalny	Element występuje raz lub w ogóle nie występuje
+	Wymagany i powtarzalny	Element występuje raz lub wielokrotnie
*	Opcjonalny i powtarzalny	Element nie występuje lub występuje wielokrotnie

18

Przykłady modeli elementów

DTD: **<!ELEMENT daneKontaktowe (id, (nazwa | telefon | email))>**

XML:

<daneKontaktowe>

<id>3</id>

<nazwa>Jan Kowalski</nazwa>

</daneKontaktowe>

XML:

<daneKontaktowe>

<id>3</id>

<telefon>1234567</telefon>

</daneKontaktowe>

XML:

<daneKontaktowe>

<id>3</id>

<email>jk@p.pl</email>

</daneKontaktowe>

DTD: **<!ELEMENT daneKontaktowe (id, nazwa?)>**

XML:

<daneKontaktowe>

<id>3</id>

<nazwa>Jan Kowalski</nazwa>

</daneKontaktowe>

XML:

<daneKontaktowe>

<id>3</id>

</daneKontaktowe>

DTD: **<!ELEMENT daneKontaktowe (id, nazwa*)>**

XML:

<daneKontaktowe>

<id>3</id>

<nazwa>Jan Kowalski</nazwa>

</daneKontaktowe>

XML:

<daneKontaktowe>

<id>3</id>

<nazwa>Jan Kowalski</nazwa>

<nazwa>Jan Nowak</nazwa>

<nazwa>Jan X</nazwa>

</daneKontaktowe>

XML:

<daneKontaktowe>

<id>3</id>

</daneKontaktowe>

19

Przykłady modeli elementów

DTD: <!ELEMENT daneKontaktowe
((id,nazwa) | (nazwa,telefon,email)) >

XML:
<daneKontaktowe>
<id>123</id>
</daneKontaktowe>

XML:
<daneKontaktowe>
<nazwa>Jan Kowalski</nazwa>
</daneKontaktowe>

XML:
<daneKontaktowe>
<nazwa>Jan Kowalski</nazwa>
<telefon>234567</telefon>
<email>jan.kowalski@wp.pl</email>
</daneKontaktowe>

DTD: <!ELEMENT daneKontaktowe (id, (nazwa | tel | email)?) >

XML:
<daneKontaktowe>
<id>123</id>
</daneKontaktowe>

XML:
<daneKontaktowe>
<nazwa>Jan Kowalski</nazwa>
</daneKontaktowe>

XML:
<daneKontaktowe>
<id>123</id>
<tel>12345</tel>
</daneKontaktowe>

XML:
<daneKontaktowe>
<id>123</id>
<email>jan.kowalski@wp.pl</email>
</daneKontaktowe>

DTD:
<ELEMENT biblioteka (książka*) >
<ELEMENT książka (autor+, tytuł, podtytuł?)>
<ELEMENT autor (#PCDATA)>
<ELEMENT tytuł (#PCDATA)>
<ELEMENT podtytuł (#PCDATA)>

20

Definicja atrybutu

<!ATTLIST nazwaElementu nazwaAtrybutu typ zawartość>

Typ	Opis
CDATA	Zawiera dane znakowe
ID	Zawiera nazwę XML, która jest niepowtarzającym się identyfikatorem. W deklaracji atrybutu dla danego elementu może wystąpić tylko jeden atrybut o typie ID
IDREF	Zawiera odwołanie do niepowtarzającego się identyfikatora. Wartość tego atrybutu musi odpowiadać wartości ID w innym elemencie danego dokumentu
IDREFS	Zawiera listę odwołań do niepowtarzających się identyfikatorów (oddzielonych spacjami)
NTOKEN	Słowo, symbol – nazwa może składać się z liter, cyfr, znaku podkreślenia, myślnika, kropki, dwukropka i nie może zawierać białych znaków
NTOKENS	Zbiór słów, symboli oddzielonych od siebie znakami spacji

21

Definicja atrybutu

<!ATTLIST nazwaElementu nazwaAtrybutu typ zawartość>

Typ	Opis
ENTITY	Zawiera nazwę nieanalizowanej jednostki (plik, obraz, tekst) – jest rodzajem zmiennej, pod którą kryje się dalsza informacja
ENTITIES	Zawiera nazwy wielu nieanalizowanych jednostek
NOTATION	Umożliwienie wstawienia instrukcji niezgodnych z językiem XML, a podlegających restrykcjom programu zewnętrznego
wyliczeniowy	Zawiera listę możliwych wartości atrybutu – lista jest umieszczana w nawiasach okrągłych, a elementy rozdzielone są znakiem „ ”

22

Definicja atrybutu

<!ATTLIST nazwaElementu nazwaAtrybutu typ zawartość>

Kwalifikatory zawartości	Znaczenie
#REQUIRED	Atrybut jest obowiązkowy, bez określenia wartości
#IMPLIED	Atrybut jest opcjonalny
"wartość"	Wartością domyślną atrybutu jest "wartość"
#FIXED "wartość"	Wartość stała, zawsze taka sama

23

Przykłady modeli atrybutów

DTD:
<ELEMENT spisKsiazek (tytuł, autor)>
<ELEMENT tytuł (#PCDATA)>
<!ATTLIST tytuł pozycja NMTOKENS #IMPLIED>
<ELEMENT autor (#PCDATA)>
<!ATTLIST autor imię NMTOKEN #REQUIRED>

XML:
<spisKsiazek>
<tytuł pozycja="półka 5 po lewej stronie od biurka">Mitologia</tytuł>
<autor imię="Jan">Parandowski</autor>
</spisKsiazek>

XML:
<spisKsiazek>
<tytuł>Mitologia</tytuł>
<autor imię="Jan">Parandowski</autor>
</spisKsiazek>

XML:
<spisKsiazek>
<tytuł pozycja="półka 5 po lewej stronie od biurka">Mitologia</tytuł>
<autor imię="Jan">Parandowski</autor>
</spisKsiazek>

XML:
<spisKsiazek>
<tytuł>Mitologia</tytuł>
<autor imię="Jan">Parandowski</autor>
</spisKsiazek>

24

Przykłady modeli atrybutów

DTD:
<ELEMENT spisKsiazek (tytuł*)>
<ELEMENT tytuł (#PCDATA)>
<!ATTLIST tytuł gatunek
(romans | kryminał | horror | klasyka) "klasyka">

XML:
<spisKsiazek>
<tytuł gatunek="klasyka">Mitologia</tytuł>
<tytuł gatunek="romans">Ptaki ciemnych krzewów</tytuł>
<tytuł>Zemsta</tytuł>
</spisKsiazek>

XML:
<spisKsiazek>
<tytuł gatunek="klasyka">Mitologia</tytuł>
<tytuł gatunek="romans">Ptaki ciemnych krzewów</tytuł>
<tytuł gatunek="klasyka">Zemsta</tytuł>
</spisKsiazek>

Przykłady modeli atrybutów

DTD:

```
<!ELEMENT biblioteka (autorzy, książki, czytelnicy,
    raport)>
<!ELEMENT autorzy (autor*)>
<!ELEMENT autor (#PCDATA)>
<!ATTLIST autor idAutora ID #REQUIRED>
<!ELEMENT książki (książka+)>
<!ELEMENT książka (tytuł+)>
<!ELEMENT tytuł (#PCDATA)>
<!ATTLIST książka idKsiążka ID #REQUIRED
    idAutora IDREF #IMPLIED>
<!ELEMENT czytelnicy (czytelnik+)>
<!ELEMENT czytelnik (#PCDATA)>
<!ATTLIST czytelnik idOsoby ID #REQUIRED>
<!ELEMENT raport (#PCDATA)>
<!ATTLIST raport idKsiążkaIdAutorIdOsoba IDREFS #REQUIRED>
```

XML:

```
<biblioteka>
  <autorzy>
    <autor idAutora="A4">J. Paradowski</autor>
  </autorzy>
  <książki>
    <książka idKsiążka="K1" idAutora="A4">
      <tytuł>Mitologia</tytuł>
    </książka>
  </książki>
  <czytelnicy>
    <czytelnik idOsoby="O6">Jan Kowalski</czytelnik>
  </czytelnicy>
  <raport idKsiążkaIdAutorIdOsoba="K1 A4 O6"/>
</biblioteka>
```

Przykłady modeli atrybutów

DTD:

```
<!ELEMENT spisKsiazek (książka*)>
<!ELEMENT książka EMPTY>
<!ATTLIST książka
    tytuł CDATA #REQUIRED
    autor CDATA #REQUIRED
    liczbaStron NMTOKEN #IMPLIED
    oprawa NMTOKEN #FIXED "twarda"
    gatunek (romans | kryminal | horror | klasyka|inny) "inny"
    wlasciciel CDATA "Biblioteka PL" >
```

XML:

```
<spisKsiazek>
  <książka tytuł="Mitologia" autor="Jan Paradowski" />
  <książka tytuł="Toscanini: Bourne'a" autor="Robert Indium" liczbaStron="450" />
  <książka tytuł="Raport Bellama" autor="John Grisham" liczbaStron="300"
    oprawa="twarda" gatunek="kryminal" wlasciciel="ZOM" />
</spisKsiazek>
```

*spisKsiazek

```
<książka tytuł="Mitologia" autor="Jan Paradowski" oprawa="twarda" gatunek="romans" wlasciciel="Biblioteka PL"/>
<książka tytuł="Toscanini: Bourne'a" autor="Robert Indium" liczbaStron="450" oprawa="twarda" gatunek="romans" wlasciciel="Biblioteka PL"/>
<książka tytuł="Raport Bellama" autor="John Grisham" liczbaStron="300" oprawa="twarda" gatunek="kryminal" wlasciciel="ZOM"/>
</spisKsiazek>
```

Przykłady modeli atrybutów

- Zawiera nazwę nieanalizowanej jednostki (plik, obraz, tekst) – jest rodzajem zmiennej, pod którą kryje się dalsza informacja

DTD:

```
<!ATTLIST film plik ENTITY #REQUIRED>
```

XML:

```
<film plik="X-Man-trailer.avi"/>
```

DTD:

```
<!ATTLIST pokaz slajdy ENTITIES #REQUIRED>
```

XML:

```
<pokaz slajdy="slajd1 slajd2 slajd4 slajd7"/>
```

Przykłady modeli atrybutów

- Umożliwienie wstawienia instrukcji niezgodnych z językiem XML, a podlegających restrykcjom programu zewnętrznego

DTD:

```
<!NOTATION gif SYSTEM "image/gif">
<!NOTATION tiff SYSTEM "image/tiff">
<!NOTATION jpeg SYSTEM "image/jpeg">
<!NOTATION png SYSTEM "image/png">
<!ATTLIST image type NOTATION (gif | tiff | jpeg | png) #REQUIRED>
```

Dwie twarze XML-a

- Dwa zastosowania XML-a
 - Zarządzanie treścią (dokumenty tworzone przez człowieka i przeznaczone dla człowieka, o długim czasie życia), np. Wielka Encyklopedia Powszechna PWN
 - Elektroniczna wymiana danych – komunikacja między aplikacjami (dokumenty tworzone oraz przetwarzane automatycznie, zazwyczaj kończące życie wraz z końcem komunikacji), np. komunikaty o błędach
- Tym dwóm zastosowaniom odpowiadają dwa modele zawartości XML-owej: „tekstowy” i „bazodanowy”

XML „tekstowy” a XML „bazodanowy”

```
<haslo> <osoba> William Szekspir </osoba> (ang. <wariant>
William Shakespeare </wariant>; ur. prawdopodobnie
<data-ur> 23 kwietnia 1564 </data-ur> w
<miejace-ur> Stratford-upon-Avon </miejace-ur>, zm.
<data-sm> 23 kwietnia 1616 </data-sm> tamże) – angielski
poeta, dramaturg, aktor. </haslo>
```

```
<zamowienie id="1">
  <pozycja>
    <nazwa> cyklotron </nazwa>
    <jednostka> sztuka </jednostka>
    <ilosc> 3 </ilosc>
  </pozycja>
  <zamawiajacy id="2" />
</zamowienie>
```

31

XML „tekstowy” a XML „bazodanowy” Model „tekstowy znormalizowany”

```
<haslo>
  <osoba> William Szekspir </osoba>
  <tekst> (ang. </tekst>
  <variant> William Shakespeare </variant>
  <tekst> ; ur. prawdopodobnie </tekst>
  <data-ur> 23 kwietnia 1564 </data-ur>
  <tekst> w </tekst>
  <miejsce-ur> Stratford-upon-Avon </miejsce-ur>
  <tekst> , zm. </tekst>
  <data-sm> 23 kwietnia 1616 </data-sm>
  <tekst> także) – angielski poeta, dramaturg, aktor. </tekst>
</haslo>
```

32

Dylemat projektanta – element czy atrybut?

```
<zamowienie>
  <nr> 12345 </nr>
  <zamawiajacy> FTIMS </zamawiajacy>
  <kodTowaru> 987512 </kodTowaru>
  <kodTowaru> 657493 </kodTowaru>
</zamowienie>
```

```
<zamowienie nr="12345" zamawiajacy="FTIMS" kodTowaru="987512 657493" />
```

```
<zamowienie>
  Zamowienie <nr> 12345 </nr>
  dla <jednostka> FTIMS </jednostka>
  na dostawę towaru <towar kod="987512"> kserokopiarki </towar>
  i <towar kod="657493"> papier ksero </towar>
</zamowienie>
```

33

Dylemat projektanta – element czy atrybut?

- Warto pamiętać o pewnych dobrych praktykach
 - W elementach warto przechowywać dane, w atrybutach metadane
 - W elementach zapisujemy tekst wizualizowany, w atrybutach jego parametry
 - Elementy zgnieżdżone nadają się świetnie do przechowywania informacji szczegółowych (opisy, listy, pozycje ...), bo atrybuty nie mogą zawierać wewnętrznej struktury (niby można użyć atrybutów typu NMTOKENS i IDREFS, ale ...)
 - Kolejność atrybutów nie ma znaczenia, natomiast w przypadku elementów jest ważna
 - W DTD tylko atrybutom można nadawać wartości domyślne, stałe, określać typ wyliczeniowy

34

Dylemat projektanta – element czy atrybut?

- Zalety elementów
 - Mogą zawierać inne elementy i atrybuty
 - Mogą się powtarzać
 - Można bezpiecznie rozszerzać ich model zawartości
 - Można dokładnie sterować sposobem ich występowania - kolejność, liczba wystąpień
- Zalety atrybutów
 - Szybsze do definiowania
 - Mogą mieć wartości domyślne

35

Związywanie dokumentu XML-owego z DTD – wariant 1

- Można zapisać DTD bezpośrednio w dokumencie (**wewnętrzne DTD**), w którym będzie użyte, podając po słowie kluczowym DOCTYPE nazwę elementu głównego, a następnie definicje elementów i atrybutów
- Zalety
 - Stosowanie jest wygodne, gdy ograniczymy się do danego dokumentu
 - Potrzeba testowania przykładowego dokumentu pod kątem zgodności DTD dla złożonego projektu

```
<?xml version="1.0" encoding="UTF-8" ?>
<!DOCTYPE opis [
  <!ELEMENT opis (#PCDATA)>
]>
<opis>To jest pierwszy dokument z wewnętrznym DTD</opis>
```

36

Wewnętrzny DTD

```
<?xml version="1.0" ?>
<!DOCTYPE zamowienie [
  <!ELEMENT zamowienie (klient)>
  <!ELEMENT klient (id_konta, nazwa)>
  <!ELEMENT id_konta (#PCDATA)>
  <!ELEMENT nazwa (imie, nazwisko)>
  <!ELEMENT imie (#PCDATA)>
  <!ELEMENT nazwisko (#PCDATA)>
]>
<zamowienie>
  <klient>
    <id_konta>1234556</id_konta>
    <nazwa>
      <imie>Jan</imie>
      <nazwisko>Kowalski</nazwisko>
    </nazwa>
  </klient>
</zamowienie>
```

```
<zamowienie>
  <klient>
    <id_konta>1234556</id_konta>
    <nazwa>
      <imie>Jan</imie>
      <nazwisko>Kowalski</nazwisko>
    </nazwa>
  </klient>
</zamowienie>
```

37

Związywanie dokumentu XML-owego z DTD – wariant 2

- Można zdefiniować DTD osobno i użyć go podając URI pliku
- Zalety
 - Możliwość zastosowania do wielu dokumentów
- Rodzaje definicji
 - Publiczne DTD** są definicjami, które zostały poddane standaryzacji i zapewniają ogólnie dostępny zestaw reguł tworzenia określonych typów dokumentów XML
 - Niepubliczne DTD** są definicjami utworzonymi przez organizacje prywatne lub pojedyncze osoby

38

Publiczne DTD

```
<!DOCTYPE spec PUBLIC
  "-//W3C//DTD Specification V2.0//EN"
  "XML/1998/06/xmlspec-v2.0.dtd">
```

- Opis elementów
 - Znak minus wskazuje, że DTD nie jest rozpoznanym standardem
 - Znak plus oznacza, że DTD jest standardem rozpoznanym
 - W3C określa właściciela DTD, w tym wypadku W3C
 - DTD Specification V2.0 jest to typ dokumentu DTD i numeru wersji. Etykieta może zawierać dowolne znaki standardowe za wyjątkiem podwójnego ukośnika [/]
 - EN dwuliterowy skrót języka dokumentu XML, do którego dana definicja DTD jest stosowana
 - Pełna lista skrótów określających języki znajduje się w specyfikacji ISO 639-1

39

Niepubliczne DTD

```
<?xml version="1.0" encoding="UTF-8" ?>
<!DOCTYPE opis SYSTEM "zewnetrznyDTD.dtd">

<opis>
  To jest pierwszy dokument z wewnętrznym DTD
</opis>

<ELEMENT opis (#PCDATA)>
```

```
<?xml version="1.0" encoding="UTF-8" ?>
<!DOCTYPE opis SYSTEM "http://www.przyklad.pl/opisDTD.dtd">

<opis>
  To jest pierwszy dokument z wewnętrznym DTD
</opis>

<ELEMENT opis (#PCDATA)>
```

40

Niepubliczne DTD

```
<?xml version="1.0" standalone="no" ?>
<!DOCTYPE zamówienie SYSTEM "zewnetrznyDTD.dtd">
<zamówienie>
  <klient>
    <id_konta>1234556</id_konta>
    <nazwa>
      <imie>Jan</imie>
      <nazwisko>Kowalski</nazwisko>
    </nazwa>
  </klient>
</zamówienie>
```

```
<ELEMENT zamówienie (klient)>
<ELEMENT klient (id_konta, nazwa)>
<ELEMENT id_konta (#PCDATA)>
<ELEMENT nazwa (imie, nazwisko)>
<ELEMENT imie (#PCDATA)>
<ELEMENT nazwisko (#PCDATA)>
```

```
<zamówienie>
  <klient>
    <id_konta>1234556</id_konta>
    <nazwa>
      <imie>Jan</imie>
      <nazwisko>Kowalski</nazwisko>
    </nazwa>
  </klient>
</zamówienie>
```

41

Związywanie dokumentu XML-owego z DTD – wariant 3

- Można połączyć obie metody (gdy chce się uzupełnić/zmienić istniejące DTD)


```
<?xml version="1.0" standalone="no" ?>
<!DOCTYPE zamówienie SYSTEM "zewnetrznyDTD.dtd" [
  <!ATTLIST klient nr CDATA #IMPLIED>
]>
<zamówienie>
  <klient nr="1">
    <id_konta>1234556</id_konta>
    <nazwa>
      <imie>Jan</imie>
      <nazwisko>Kowalski</nazwisko>
    </nazwa>
  </klient>
</zamówienie>
```

```
<ELEMENT zamówienie (klient)>
<ELEMENT klient (id_konta, nazwa)>
<ELEMENT id_konta (#PCDATA)>
<ELEMENT nazwa (imie, nazwisko)>
<ELEMENT imie (#PCDATA)>
<ELEMENT nazwisko (#PCDATA)>
```

42

Fizyczna struktura dokumentu – encje

- Umożliwiają one nazywanie fragmentów tekstu (znaków, ciągów znaków, zawartości plików) w celu ich późniejszego wykorzystania
- Dzięki temu, poprzez odwołanie do tych nazw, możliwe jest wielokrotne wykorzystanie raz zadeklarowanych fragmentów



43

Encje ogólne wewnętrzne

- Skrót odniesień do tekstu lub danych, które w dokumencie powinny zostać zamienione
- Są zawsze wartościami tekstowymi
- Znaki zarezerwowane dla składni XML-owej daje się uzyskać używając tzw. encji predefiniowanych (& dla &, < dla <, > dla >, ' dla ', " dla ")
- Odwolania do znaków
 - &#k;od; - kod dziesiętny znaku
 - &#xk;od; - kod szesnastkowy znaku

```
<!ENTITY nazwaJednostki zawartośćJednostki>
&nazwaJednostki;
```

44

Encje ogólne wewnętrzne

```
<?xml version="1.0" ?>
<!DOCTYPE student [
  <!ENTITY fims "Fizyka Techniczna, Informatyka i Matematyka Stosowana">
  <!ENTITY OIZ "Organizacja i zarządzanie">
  <!ELEMENT student (imię, nazwisko)>
  <!ATTLIST student wydział CDATA "&fims;">
  <!ELEMENT imię (#PCDATA)>
  <!ELEMENT nazwisko (#PCDATA)>
]>
<student>
  <imię>Jan</imię>
  <nazwisko>Kowalski</nazwisko>
</student>

<student wydział="OIZ">
  <imię>Jan</imię>
  <nazwisko>Kowalski</nazwisko>
</student>

<student wydział="Organizacja i zarządzanie">
  <imię>Jan</imię>
  <nazwisko>Kowalski</nazwisko>
</student>
```

45

Encje ogólne zewnętrzne

- Mogą być tekstem lub innym typem danych (np. obraz) i są zawsze przechowywane w zewnętrznym pliku
 - Przechwazane - mogą być one prywatne (zadeklarowane poprzez słowo SYSTEM) lub publiczne (zadeklarowane poprzez słowo PUBLIC)
 - Nieprzechwazane jednostki są przesyłane do aplikacji obsługującej dokument (done)

```
<!ENTITY nazwaJednostki SYSTEM "plik.ent">
&nazwaJednostki;
```

```
<!ENTITY nazwaJednostki PUBLIC "plik.ent">
&nazwaJednostki;
```

46

Encje ogólne zewnętrzne

```
<?xml version="1.0" ?>
<!DOCTYPE student [
  <!ENTITY fims SYSTEM "fims.ent">
  <!ELEMENT student (imię, nazwisko, wydział)>
  <!ELEMENT imię (#PCDATA)>
  <!ELEMENT nazwisko (#PCDATA)>
  <!ELEMENT wydział (#PCDATA)>
]>
<student>
  <imię>Jan</imię>
  <nazwisko>Kowalski</nazwisko>
  <wydział>&fims;</wydział>
</student>

<fims>Fizyka Techniczna, Informatyka i Matematyka Stosowana</fims>
<przedmiot>Programowanie komunikacji człowiek-komputer</przedmiot>
<semestr>7</semestr>
```

47

Encje w atrybutach i notacji

- Nazwa encji nieprzetwarzanej (ang. *unparser external entity*) może być też wartością atrybutu typu ENTITY
- Dostarczają informacji dotyczących nieanalizowanej części dokumentu oraz takich, które są najczęściej wykorzystywane razem z zewnętrzną nieanalizowaną encją ogólną
- Analizatory XML nie wykorzystują notacji
- Są natychmiast przesyłane do aplikacji obsługującej dokument

```
<!NOTATION nazwaTypDanych SYSTEM adresDoDanych>
```

48

Encje w atrybutach i notacji

```
DTD:
<!DOCTYPE rysunek [
  <!ELEMENT rysunek EMPTY>
  <!ATTLIST rysunek plik ENTITY #REQUIRED>
  <!ENTITY mójRysunek SYSTEM
    "http://mojaStrona/rys1.jpg" NDATA jpeg>
  <!NOTATION jpeg SYSTEM "image/jpeg">
]>
```

Aby móc użyć takiego zapisu, encji musi zostać przypisana notacja – poprzez określenie formatu encji oraz osobną deklarację notacji wraz z dodatkową informacją dla aplikacji zewnętrznej

```
XML:
<rysunek plik="mójRysunek">
```

Element rysunek odwołuje się do fotografii <http://mojaStrona/rys1.jpg>

49

Encje parametryczne wewnętrzne

```
<!ENTITY % nazwaJednostki zawartoscJednostki>
```

```
%nazwaJednostki;
```

- Uniknięcie powtarzania części definicji DTD
- Daje to jedną lokalizację dla wspólnych i powtarzalnych elementów

```
<!ELEMENT firma (nazwa, ulica, miasto, kod, telefon*, email*, web*, inne*)>
<!ELEMENT kontakt (nazwa, ulica, miasto, kod, telefon*, email*, web*, inne*)>
<!ELEMENT osoba (nazwa, ulica, miasto, kod, telefon*, email*, web*, inne*)>
```

```
<!ENTITY % dane_kontaktowe "nazwa, ulica, miasto, kod">
<!ENTITY % dane_opcjonalne "telefon*, email*, web*, inne*">
```

```
<!ELEMENT firma (%dane_kontaktowe;, %dane_opcjonalne;)>
<!ELEMENT kontakt (%dane_kontaktowe;, %dane_opcjonalne;)>
<!ELEMENT osoba (%dane_kontaktowe;, %dane_opcjonalne;)>
```

50

Encje parametryczne zewnętrzne

- Umożliwienie dołączania jednej DTD do innej
- Deklaracja i wykorzystanie są bardzo podobne do deklaracji wewnętrznych jednostek parametrycznych
 - Deklaracja rozpoczyna się słowem kluczowym ENTITY, po którym znajduje się znak procentu (%)
 - Następnie w deklaracji umieszcza się słowa kluczowe SYSTEM lub PUBLIC, które wskazują że źródło jednostki znajduje się w pliku zewnętrznym
 - Na końcu, wewnątrz znaków cudzysłowu, umieszczony zostaje URI

```
<!ENTITY % nazwaJednostki SYSTEM plikDTD>
```

```
%nazwaJednostki;
```

51

Ograniczenia DTD

- Brak możliwości ograniczenia tekstowej treści elementów
- Brak wartości domyślnych dla elementów
- Słabe możliwości kontroli typów atrybutów
- Brak możliwości deklarowania typów zawartości wykorzystywanych dla wielu elementów i atrybutów
- Brak deklaracji dowolnego elementu lub atrybutu, dla którego użytkownik sam dobiera nazwę w dokumencie XML
- Brak możliwości zmiany kolejności elementów
- Brak możliwości ustalenia kolejności atrybutów
- DTD zawarte w standardzie XML 1.0 nie wspiera przestrzeni nazw

52

Ograniczenia DTD

- Słaba modułowość
- Brak rozbudowanych możliwości dokumentowania
- Brak możliwości uzależnienia treści lub wartości atrybutów od zawartości elementów lub atrybutów
- Brak możliwości kontroli typów w zależności od miejsca wystąpienia podelementu
- Typ ID dla atrybutów ma zbyt wiele ograniczeń
- Syntaktyka DTD jest inna niż zwykłego dokumentu XML

53

DTD vs XML Schema

- | | |
|--|--|
| <ul style="list-style-type: none"> Wychodzi się z SGML-a Specyficzna składnia 10 typów danych Brak kontroli tekstowej zawartości elementów Typowy mieszany model zawartości | <ul style="list-style-type: none"> Zaprojektowany na potrzeby XML Składnia XML 44 wbudowane typy proste Zaawansowana kontrola tekstowej zawartości elementów Możliwość definiowania własnych typów danych |
|--|--|